



CS114.Q22



ỨNG DỤNG MACHINE LEARNING

DỰ ĐOÁN TỶ LỆ CHUYỂN ĐỔI KHÁCH HÀNG TRÊN BỘ DỮ LIỆU LEAD SCORING

Nhóm sinh viên thực hiện:

23520825 - Võ Anh Kiệt

23520824 - Võ Anh Kiệt

23520816 - Phạm Anh Kiệt


23520845 - Lê Xuân Song Lĩnh

23520878 - Lê Quang Long

Giảng viên :

TS. Võ Nguyễn Lê Duy





Section

- 01 *Giới thiệu bài toán và dữ liệu*
- 02 *Exploratory Data Analysis*
- 03 *Data Processing*
- 04 *Huấn luyện mô hình*
- 05 *Thực nghiệm*
- 06 *Demo*





Section 01:

Giới thiệu bài toán và dữ liệu

- a. Giới thiệu bài toán*
- b. Bộ dữ liệu Lead Scoring của X Education*

1.1. Giới thiệu bài toán

- Thị trường giáo dục trực tuyến cạnh tranh khốc liệt đòi hỏi doanh nghiệp phải tối ưu hóa quy trình bán hàng
- Thu hút lượng lớn khách hàng tiềm năng (leads) mỗi ngày qua website và marketing.
- Tỷ lệ chuyển đổi thực tế chỉ đạt 30%.
- Việc chăm sóc khách hàng dàn trải, thiếu phân loại khiến đội ngũ Sales quá tải, gây lãng phí lớn về thời gian, nhân lực và làm tăng chi phí vận hành.

1.2. Mục tiêu nghiên cứu

- Dự đoán khả năng chuyển đổi (Converted): Biến mục tiêu là Converted (1: đã chuyển đổi, 0: chưa chuyển đổi).
- Xác định các yếu tố ảnh hưởng: Tìm ra các đặc trưng, hành vi và kênh tiếp cận then chốt quyết định kết quả chuyển đổi.

Bộ dữ liệu Lead Scoring của X Education

Dataset trong bài toán **Lead Scoring** của X Education gồm khoảng 9000 mẫu dữ liệu khách hàng tiềm năng. Dữ liệu chứa nhiều thuộc tính liên quan đến:

- *Nguồn khách hàng,*
- *Hành vi truy cập website,*
- *Hoạt động tương tác,*
- *Thông tin nghề nghiệp,*
- *Chất lượng khách hàng tiềm năng.*

Biến mục tiêu là **Converted**, dùng để xác định khách hàng có chuyển đổi thành khách hàng thực tế hay không:

- **1: đã chuyển đổi,**
- **0: chưa chuyển đổi.**

Dataset được sử dụng để xây dựng mô hình Machine Learning nhằm dự đoán khả năng chuyển đổi của khách hàng và **hỗ trợ hệ thống Lead Scoring.**



CS114.Q22

Section 02:
Exploratory Data Analysis
Phân tích và khai phá dữ liệu

Quan sát chung. Bộ dữ liệu gồm có 37 feature với 9240 data samples gồm các cột dữ liệu dạng số và dạng phân loại hoặc chuỗi ký tự

i 1. Nhóm thông tin định danh và nguồn gốc lead

- **Ví dụ.** Prospect ID, Lead Number, Lead Origin, Lead Source, How did you hear about X Education

i 2. Nhóm hành vi tương tác và hoạt động trên website


- **Ví dụ.** TotalVisits, Total Time Spent on Website, Page Views Per Visit, Last Activity

i 3. Nhóm hành vi tương tác trên website.

- **Ví dụ.** Country, City, Specialization, What is your current occupation, What matters most to you in choosing a course, Lead Profile

i 4. Nhóm thông tin cá nhân và hồ sơ lead.

- **Ví dụ.** Tags, Lead Quality, Asymmetrique Activity Index, Asymmetrique Profile Index




Mô tả dữ liệu


- 45.95% số lượng cột bị thiếu

Nhóm các cột

- Lead Quality
- Asymmetrique Activity Index
- Asymmetrique Profile Score
- Asymmetrique Activity Score
- Asymmetrique Profile Index
- Tags
- Lead Profile

> 29%





Phân phối dữ liệu của biến mục tiêu


- Converted = 1 ($\approx 39,2\%$)
- Converted = 0 ($\approx 60,8\%$)

Con số này cho thấy dữ liệu tương đối mất cân bằng (imbalanced)


Tags and Converted

Tags	Số lượng Converted=1	Tổng số	Tỷ lệ chuyển đổi (%)
Will revert after reading the email	1.785	1.850	96,5%
Closed by Horizzon	323	325	99,4%
Busy	104	182	57,1%
Lost to EINS	162	166	97,6%
Interested in Next batch	5	5	100%
Already a student	3	383	0,8%
Not doing further education	1	141	0,7%
Ringing	34	1.117	3,0%
Unknown	596	2.328	25,6%

- Một số nhãn gần như **dự báo rất tốt khả năng chuyển đổi**: **Closed by Horizzon** đạt **99.4%**, **Will revert after reading the email** đạt **96.5%**, trong khi **Ringing** chỉ **3.0%**, **Already a student** chỉ **0.8%**.
- **Vấn đề**: Cột Tags này do nhân viên đánh nhãn
Pineline tự động → Drop cột Tags



Section #2



- Từ biểu đồ heatmap, có thể thấy nhóm **Working Professional** có tỷ lệ chuyển đổi cao nhất ở hầu hết các chuyên ngành. Nhiều nhóm trong **Working Professional** đạt tỷ lệ chuyển đổi rất cao, trên **90%**.
- **Unknown** có tỷ lệ chuyển đổi thấp hơn rõ rệt. Nhiều chuyên ngành trong nhóm này chỉ có tỷ lệ chuyển đổi **khoảng 10% đến 20%**.



Section 03: ***Data Processing***

- a. Làm sạch dữ liệu - Data Cleaning*
- b. Xử lý Outliers - Outliers Handling*
- c. Thiết kế bộ đặc trưng - Feature Engineering*
- d. Train Test Split*
- e. Scaling dữ liệu*
- f. Chọn lựa đặc trưng - Feature Selection*




Section 03:
Data Processing
a. Làm sạch dữ liệu - Data Cleaning

Mục tiêu: Giữ lại những thông tin có ý nghĩa dự đoán, giảm nhiễu trước khi xử lý tiếp.

Logic xử lý chính

- Bỏ cột định danh: Prospect ID, Lead Number
- Bỏ cột nhiều missing, khó khai thác ổn định
- Bỏ cột gần như một giá trị → ít thông tin phân loại
- Missing: category → “Unknown”, numeric → median
- Loại bản ghi trùng sau khi giảm chiều dữ liệu





Section 03:
Data Processing
b. Xử lý Outliers - Outliers Handling

Dữ liệu số

- Dùng IQR method để nhận diện và xử lý outliers.

Thuật toán IQR

- Chia dữ liệu thành các khoảng phân vị Q1, Q2, Q3.
- $IQR = Q3 - Q1$.
- Giá trị ngoài $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$ được chặn về biên.

Dữ liệu danh mục

- Category có tần suất $< 1\%$ được xem là outlier.
- Không xóa tùy tiện: gộp có ý nghĩa nghiệp vụ để giữ thông tin.

Ví dụ


Lead Source

- Google/google → Google
- Olark/Live Chat → Chat
- Referral/Reference → Referral




Specialization

- Finance + Banking → Finance & Banking
- Marketing + Media → Marketing & Advertising
- Unknown/Select → Not Specified

Trước khi xử lý



Sau khi xử lý







Section #3b

DỮ LIỆU DANH MỤC

Trước khi xử lý

Sau khi xử lý





Section 03: ***Data Processing***


c. Thiết kế bộ đặc trưng - Feature Engineering

Biến hành vi truy cập website thành “tín hiệu mức độ quan tâm” cho mô hình Lead Scoring.

Hành vi gốc

Dữ liệu ban đầu mô tả cách lead tương tác với website

- **Visits:** Số lần truy cập
- **Page Views:** Mức đọc nội dung
- **Time Spent:** Mức quan tâm



Tạo đặc trưng mới

Mục tiêu: gom các chỉ số rời rạc thành tín hiệu dễ hiểu hơn.

- **Tương tác giữa biến**
 - $\text{Time} \times \text{Page}$ | $\text{Time} \times \text{Visit}$ | $\text{Page} \times \text{Visit}$
- **Cường độ theo trang/phiên**
 - Time/Page | Time/Visit
- **Engagement Score**
 - $25\% \text{ Visits} + 25\% \text{ PageViews} + 50\% \text{ Time}$
- **Engagement Level**
 - 0–3 hành vi vượt median → Low / Mid / High



Section 03:
Data Processing
d. Train Test Split

Dùng **train_test_split()** của *Sklearn*

Tỷ lệ chia:

+ **Training Set:** 80% (6152 dòng)

+ **Testing Set:** 20% (1538 dòng)

# Lead Origin		# Lead Source	# Do Not Email	# Do Not Call	# TotalVisits
1536	0	2	0	0	4.0
4660	1	1	0	0	2.0
4410	0	2	0	0	2.0
501	1	3	0	0	6.0
2432	1	2	0	0	3.0
6922	1	3	0	0	5.0
2441	0	2	0	0	2.0
1539	1	3	0	0	3.0
3656	0	1	0	0	8.0
7682	1	1	0	0	2.0



Section 03:
Data Processing
e. Scaling dữ liệu

'Total Time Spent on Website'

'Page Views Per Visit'

'TotalVisits'

'Time_Per_Page'

'Time_Per_Visit'


'Engagement_Score'

'Engagement_Level'

'ttspow_pvps'

'tttspow_totalvisits'

'pvps_totalvisits'



Standard Scaler

$$z = \frac{X - \mu}{\sigma}$$

- Mean = 0
- SD = 1
- Affected by outliers





Section 03:

Data Processing

f. Chọn lựa đặc trưng - Feature Selection

FEATURE SELECTION

Quy trình chọn lọc 5 tầng Đặc trưng sau Engineering

Tập đặc trưng đầu vào

21

20

12

6

6

Low Variance + Duplicate

Bỏ Do Not Call; không có cột trùng

Mutual Information + Corr

Bỏ cột dư thừa khi $r > 0.7$

GBM Importance

Giữ cột có importance đủ mạnh

RFECV

Xác nhận số cột tối ưu bằng CV

6 đặc trưng cuối cùng

Thông tin Lead

Lead Origin

Last Activity

Occupation

Lead Profile

Tín hiệu hành vi

pvps_totalvisits

Engagement_Score

Feature importance nổi bật

Engagement		0.453
Lead Profile		0.124
Occupation		0.117
Last Activity		0.096

KẾT QUẢ KIỂM CHỨNG

AUC kiểm chứng: CV, Test

CV thể hiện độ ổn định khi huấn luyện; Test cho biết khả năng tổng quát trên dữ liệu chưa thấy.

Mô hình	AUC Train CV	AUC Test
Random Forest	0.8933 ± 0.0058	0.8970
Gradient Boosting	0.8972 ± 0.0063	0.8989



Section 04:

Huấn Luyện Mô Hình


- a. Các thuật toán máy học*
- b. Tối ưu siêu tham số*



Section 04:
Huấn Luyện Mô Hình
a. Các thuật toán máy học

Logistic Regression là một mô hình Machine Learning dùng cho **bài toán phân loại**, đặc biệt phổ biến trong phân loại nhị phân.

Logistic Regression dự đoán **xác suất một mẫu thuộc về một lớp nào đó**. Mô hình sử dụng hàm Sigmoid để đưa kết quả về khoảng từ 0 đến 1




Sigmoid / Logistic

$$f(x) = \frac{1}{1 + e^{-x}}$$


SUPPORT VECTOR MACHINE

Support Vector Machines (SVM)

Hyperplanes that Best Separates Different Classes




- **Support Vector Machine (SVM)** là mô hình phân loại tìm **một siêu phẳng (hyperplane)** tối ưu để **tách các lớp dữ liệu** sao cho biên (margin) giữa các lớp là lớn nhất.
- Với các **bài toán không tuyến tính**, SVM sử dụng **kernel trick** (ví dụ: RBF, polynomial) để **ánh xạ dữ liệu sang không gian đặc trưng cao hơn**, nơi các lớp có thể phân tách tuyến tính.




- **Random Forest** là mô hình phân loại dựa trên tập hợp nhiều **cây quyết định (Decision Tree)**.
- Khi dự đoán, **mỗi cây đưa ra một nhãn** và mô hình sẽ **chọn nhãn xuất hiện nhiều nhất (Majority Voting)**. Nhờ sự kết hợp của nhiều cây độc lập và việc **lấy mẫu ngẫu nhiên**, Random Forest thường cho kết quả ổn định, giảm overfitting

XGBOOST - EXTREME GRADIENT BOOSTING



- **XGBoost** là mô hình phân loại dựa trên tập hợp nhiều cây quyết định được xây dựng theo phương pháp **Boosting**.
- Khác với **Random Forest** xây nhiều cây độc lập, **XGBoost** xây **các cây tuần tự**, trong đó **cây sau học cách sửa lỗi của cây trước**. Nhờ cơ chế tối ưu mạnh mẽ và khả năng **giảm overfitting bằng regularization**, XGBoost thường cho hiệu quả cao trên dữ liệu dạng bảng.

LIGHTGBM - LIGHT GRADIENT BOOSTING MACHINE




- **LightGBM** là mô hình phân loại dựa trên **tập hợp nhiều cây quyết định**, được xây dựng theo phương pháp **Gradient Boosting**.
- Tương tự **XGBoost**, **LightGBM** xây các **cây tuần tự**, trong đó cây sau học cách cải thiện lỗi của cây trước. Điểm nổi bật của **LightGBM** là **tốc độ huấn luyện nhanh**, **xử lý tốt dữ liệu lớn** và **tối ưu hiệu quả** nhờ cách phát triển cây theo hướng **leaf-wise**.



Section 04:
Huấn Luyện Mô Hình
b. Tối ưu siêu tham số

Optuna là thư viện tối ưu **hyperparameter** cho mô hình **Machine Learning**, sử dụng **Bayesian Optimization** để chọn thử các bộ tham số tiềm năng thay vì tìm kiếm toàn bộ như **GridSearch**.



Trình tự thực hiện:

- Xây dựng một hàm **Objective**.
- Trong mỗi trial, **Optuna** đề xuất một bộ tham số cho mô hình.
- Mô hình được huấn luyện và đánh giá bằng **Cross-validation**.
- Metric dùng để đánh giá là **ROC-AUC**.
- Sau nhiều lần thử nghiệm, **Optuna** chọn ra bộ tham số cho kết quả tốt nhất.

Tree-structured Parzen Estimator Optimization Diagram (TPE)




KẾT QUẢ KHI ÁP DỤNG OPTUNA

Thuật toán	Bộ tham số
<i>Logistic Regression</i>	{ 'C' : 0.337, 'solver' : 'liblinear', 'penalty' : 'l2', 'max_iter' : 100, 'random_state' : 42}
<i>SVM</i>	{ 'kernel' : 'rbf', 'C' : 19.16, 'gamma' : 0.0377}
<i>XGBoost</i>	{ "n_estimators" : 203, "max_depth" : 3, "learning_rate" : 0.13, "subsample" : 0.97, "colsample_bytree" : 0.91, "colsample_bylevel" : 0.89, "min_child_weight" : 1, "gamma" : 0.94, "reg_alpha" : 2.39e-08, "reg_lambda" : 1.8e-06, "scale_pos_weight" : 1.67 }
<i>LightGBM</i>	{ "n_estimators" : 686, "max_depth" : 3, "num_leaves" : 118, "learning_rate" : 0.092, "min_child_samples" : 7, "subsample" : 0.97, "subsample_freq" : 7, "colsample_bytree" : 0.75, "reg_alpha" : 0.002, "reg_lambda" : 4.617e-06, "min_split_gain" : 0.332 }
<i>Random Forest</i>	{ "n_estimators" : 499, "max_depth" : 8, "max_features" : "log2", "min_samples_split" : 11, "min_samples_leaf" : 1, "max_samples" : 0.673 }

GridSearchCV là phương pháp tìm kiếm **tổ hợp siêu tham số tối ưu** cho mô hình học máy bằng cách **thử tất cả các kết hợp có thể trong một lưới (grid) tham số**. Với mỗi tổ hợp, mô hình được đánh giá bằng **Cross-Validation**, giúp đảm bảo kết quả ổn định và tránh **overfitting**.

Grid Search

```
Hyperparameter_One = [ a, b, c ]  
Hyperparameter_Two = [ x, y, z ]  
Hyperparameter_X = [ i, j, k ]
```



KẾT QUẢ KHI ÁP DỤNG GRIDSEARCH

Thuật toán	Bộ tham số
<i>Logistic Regression</i>	{ 'C' : 10, 'penalty' : 'l1', 'solver' : 'liblinear'}
<i>SVM</i>	{ 'C' : 10, 'gamma' : 'auto', 'kernel' : 'rbf'}
<i>XGBoost</i>	{ 'colsample_bytree' : 0.8, 'learning_rate' : 0.1, 'max_depth' : 3, 'n_estimators' : 100, 'subsample' : 0.8}
<i>LightGBM</i>	{ 'learning_rate' : 0.1, 'max_depth' : -1, 'n_estimators' : 100, 'num_leaves' : 31, 'subsample' : 0.8}
<i>Random Forest</i>	{ 'max_depth' : 10, 'min_samples_leaf' : 2, 'min_samples_split' : 2, 'n_estimators' : 100}



Section 05:
Thực nghiệm
a. Các độ đo đánh giá
b. Bảng kết quả thực nghiệm



Section 05:
Thực nghiệm
a. Các độ đo đánh giá

CÁC ĐỘ ĐO ĐÁNH GIÁ

		Actual	
		Positive	Negative
Predicted	Positive	True Positive	False Positive
	Negative	False Negative	True Negative

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$



Section 05:
Thực nghiệm
b. Bảng kết quả thực nghiệm

BẢNG KẾT QUẢ THỰC NGHIỆM

Metric	GridSearchCV					Optuna				
	LR	SVM	XGB	LGBM	RF	LR	SVM	XGB	LGBM	RF
F1	0.68	0.78	0.78	0.77	0.78	0.76	0.81	0.81	0.82	0.82
Accuracy	0.77	0.81	0.83	0.82	0.83	0.77	0.82	0.82	0.83	0.83
Recall	0.63	0.83	0.79	0.77	0.79	0.75	0.80	0.81	0.82	0.82
Precision	0.74	0.73	0.77	0.77	0.76	0.77	0.81	0.82	0.82	0.82



CS114.Q22

Section 6: *Demo*



Thank you for listening!

ỨNG DỤNG MACHINE LEARNING

DỰ ĐOÁN TỶ LỆ CHUYỂN ĐỔI KHÁCH HÀNG TRÊN BỘ DỮ LIỆU LEAD SCORING

